Dúvidas: Mercados Financeiros

Anotações de Estudo

13 de março de 2026

1 Dúvida 1: A Propriedade da Torre das Esperanças Condicionais

Pergunta: Eu não entendi por que $\mathbb{E}_t[\text{Payoff}] = \mathbb{E}_t[\mathbb{E}_{t+1}[\text{Payoff}]]$.

Explicação:

A equação trata da **Propriedade da Torre das Esperanças Condicionais** (ou Lei das Expectativas Iteradas). É um dos conceitos fundamentais em matemática financeira e precificação de ativos.

Vamos desconstruir a equação $\mathbb{E}_t[\text{Payoff}] = \mathbb{E}_t[\mathbb{E}_{t+1}[\text{Payoff}]]$ para entender de forma intuitiva o porquê dela ser verdade:

1.1 1. O que os símbolos significam?

- $\mathbb{E}_t[\dots]$ significa a expectativa (ou previsão) de algo **dada toda a informação disponível hoje (no momento t)**. Em linguagem matemática mais rigorosa, é $\mathbb{E}[\dots|\mathcal{F}_t]$.
- $\mathbb{E}_{t+1}[\textbf{Payoff}]$ é a expectativa do Payoff **usando toda a informação que se terá amanhã (no momento $t+1$)**.
- Observe que, olhando na perspectiva de hoje (t), a sua previsão de amanhã ($\mathbb{E}_{t+1}[\text{Payoff}]$) ainda é incerta (é uma variável aleatória), porque entre hoje e amanhã vão surgir novas notícias e informações no mercado.

1.2 2. A intuição por trás da igualdade

Imagine que o Payoff seja o preço de uma ação na sexta-feira. E vamos definir os dias:

- t = hoje (quarta-feira).
- $t+1$ = amanhã (quinta-feira).

Veja o que cada lado da equação diz:

- **Lado esquerdo ($\mathbb{E}_t[\textbf{Payoff}]$):** Qual é a sua melhor estimativa *hoje* para o preço de sexta-feira?
- **Lado direito ($\mathbb{E}_t[\mathbb{E}_{t+1}[\textbf{Payoff}]]$):** Qual é a sua melhor estimativa *hoje* sobre qual será a sua estimativa *amanhã*?

A lógica da propriedade da torre é: a sua melhor previsão hoje sobre qual será a sua própria previsão amanhã... **tem que ser igual a sua previsão de hoje!**

1.3 3. Por que não faria sentido ser diferente? (O argumento financeiro)

Se você acha hoje que amanhã terá motivos para revisar sua projeção de preço "para cima", isso significa que você *hoje* já tem uma informação otimista. Se você já tem essa informação com você, a sua estimativa de hoje já deveria estar mais alta para incorporar essa expectativa!

1.4 4. Resumo Matemático (Filtragem de Informação)

A informação no momento t (chamamos de conjunto ou sigma-álgebra $\mathcal{F}_t$) é um subconjunto da informação em $t+1$ ($\mathcal{F}_t \subseteq \mathcal{F}_{t+1}$). Isso quer dizer que o tempo não anda para trás: você não esquece as coisas amanhã que sabe hoje.

Quando você aplica primeiro o operador $\mathbb{E}_{t+1}$ você tira a incerteza do que acontece depois de $t+1$. Quando você aplica o $\mathbb{E}_t$ por fora, você está tirando a incerteza do que acontece entre t e $t+1$. O resultado é simplesmente tirar **toda** a incerteza futura e projetar para o tempo t, ou seja, $\mathbb{E}_t[\text{Payoff}]$.

É por causa dessa propriedade que o preço dos ativos descontados são modelados através do conceito de **Martingal**.

2 Dúvida 2: O que é Payoff e a Relação do Preço Hoje vs. Amanhã

Pergunta: Defina payoff e como o valor de hoje está relacionado ao de amanhã.

Explicação:

Nas finanças, a relação entre o preço de **hoje** e o valor de **amanhã** gira em torno de dois conceitos centrais: o **Payoff** (fluxo de caixa futuro) e o **Fator de Desconto Estocástico** (SDF - *Stochastic Discount Factor*).

2.1 1. O que é o Payoff?

O **Payoff** (muitas vezes denotado por X_{t+1} ou V_{t+1}) é pura e simplesmente **tudo o que o ativo te paga no futuro** (no momento $t+1$).

Se você compra um ativo hoje (t), no período seguinte ($t+1$) você terá direito ao valor de revenda desse ativo (o preço em $t+1$) mais qualquer rendimento extra que ele distribuiu no período (como dividendos ou cupons de juros).

Formulando matematicamente, para uma ação cujo preço é P e que paga um dividendo D:

$$\text{Payoff}_{t+1} = X_{t+1} = P_{t+1} + D_{t+1} \tag{1}$$

O *Payoff* é uma **variável aleatória** vista do momento t. Você não tem certeza hoje de quanto a ação vai valer amanhã, nem exatamente de quanto vai ser o dividendo.

2.2 2. Como o valor de hoje se relaciona com o de amanhã?

A regra de ouro de precificação de qualquer ativo na economia é: **O preço de hoje de um ativo é o valor esperado do seu *payoff* de amanhã, descontado para o presente.**

No entanto, como o *payoff* do futuro é incerto (tem risco), você não pode simplesmente descontá-lo pela taxa de juros livre de risco. Você usa algo chamado **Fator de Desconto Estocástico (M_{t+1})**.

A Equação Fundamental de Apreçamento de Ativos (Fundamental Pricing Equation) é:

$$P_t = \mathbb{E}_t[M_{t+1} \cdot X_{t+1}] \tag{2}$$

Onde:

- P_t: É o preço que você paga pelo ativo hoje.
- X_{t+1}: É o Payoff amanhã (Preço futuro + Dividendos).
- M_{t+1}: É o Fator de Desconto Estocástico. Ele faz o papel duplo de desvalorizar o dinheiro no tempo (como uma taxa de juros) e penalizar os estados do mundo onde a economia vai mal (ajuste de risco).
- $\mathbb{E}_t[\ldots]$: É a esperança (média probabilística) usando todas as informações que você tem hoje (t).

2.3 3. Resumo da Intuição Econômica

Em termos econômicos, a relação $P_t = \mathbb{E}_t[M_{t+1} \cdot X_{t+1}]$ significa que o investidor olha para todos os cenários possíveis de amanhã. Para cada cenário, ele pondera quanto o ativo vai pagar (X_{t+1}) multiplicado pelo quanto de "fome" (utilidade marginal, embutida no M_{t+1}) ele terá naquele cenário.

Se o ativo paga muito exatamente quando a economia vai mal (quando o investidor mais precisa de dinheiro), o preço de hoje (P_t) será **alto** (ativo de proteção/hedge). Se o ativo paga muito quando a economia vai bem, e cai quando vai mal (como a maioria das ações da bolsa), o investidor exige pagar mais **barato** hoje (prêmio de risco).

3 Dúvida 3: Qual a Variável que está sendo Integrada?

Contexto: Na seção 4.4 do projeto, a esperança condicionada é escrita explicitamente como:

$$\mathbb{E}\left[V_{t+1}(S_{t+1}, e_{t+1}) \mid S_t = x,\, e_t = e,\, b_t = a\right] \tag{7}$$

$$= \int_{\mathbb{R}^N} V_{t+1}\big(x + \xi + a,\ e \odot \mathbb{1}_{\{x+\xi+a>0\}}\big)\, dF_{X_{t+1}}(\xi) \tag{8}$$

Pergunta: Qual a variável que está sendo integrada?

3.1 1. A variável de integração é ξ (xi)

A variável que está sendo integrada é $\boldsymbol{\xi}$, que representa cada **realização possível do vetor de choques** X_{t+1}.

O símbolo $dF_{X_{t+1}}(\xi)$ é a notação de **integração de Stieltjes** em relação à função de distribuição acumulada $F_{X_{t+1}}$. Isso significa: para cada possível valor ξ que o choque X_{t+1} pode assumir, pegamos o valor da função V_{t+1} naquele ponto e ponderamos pela *probabilidade* de o choque assumir aquele valor.

3.2 2. Decomposição da Equação (8)

Identificando cada parte da integral:

- $\xi \in \mathbb{R}^N$: É *cada possível realização* do vetor de choques.
- $x + \xi + a$: É o valor da carteira *após* o choque ξ se materializar, dado que hoje a carteira vale x e a ação tomada foi a.
- $\mathbb{1}_{\{x+\xi+a>0\}}$: É uma função indicadora que vale 1 se a carteira permanecer solvente (valor positivo) e 0 caso contrário.
- $dF_{X_{t+1}}(\xi)$: É a medida de probabilidade. Diz: "qual a chance de o vetor de choques assumir o valor ξ?".

3.3 3. Conexão com a Esperança

A escrita integral é apenas a forma explícita da esperança (equação 7). Em notação compacta:

$$\mathbb{E}_\xi\big[V_{t+1}(x + \xi + a,\ e \odot \mathbb{1}_{\{x+\xi+a>0\}})\big] \tag{3}$$

onde a esperança $\mathbb{E}_\xi$ indica que a média é calculada sobre a distribuição do choque ξ.

3.4 4. Por que é difícil de computar?

A integral é sobre $\mathbb{R}^N$ (alta dimensionalidade), contém funções indicadoras (não suave) e requer conhecer V_{t+1} em todo o espaço de estados. Por isso a solução prática é a **aproximação de Monte Carlo**: sortear amostras aleatórias de ξ segundo a distribuição $F_{X_{t+1}}$ e calcular a média empírica de V_{t+1}.

4 Dúvida 4: Na Aproximação Linear, as Features Dependem de Valores Presentes ou Futuros?

Pergunta: Na aproximação linear da função valor, nossas features dependem apenas de valores presentes, ou também de valores futuros?

4.1 1. As features dependem apenas do estado presente

Na aproximação linear da função valor, as features dependem **apenas dos valores do estado presente**. A aproximação é escrita como:

$$V_t(s) \approx \theta^\top \phi(s) \tag{4}$$

onde $\phi(s)$ é um vetor de features computadas a partir do **estado atual** $s = (S_t, e_t)$ — por exemplo, o valor corrente da carteira, o regime econômico atual, os preços atuais dos ativos, etc.

Não é possível usar valores futuros nas features porque:

1. No momento da decisão t, os valores futuros $(S_{t+1}, e_{t+1}, \xi_{t+1})$ são **desconhecidos** — são exatamente as variáveis aleatórias sobre as quais se calcula a esperança.

2. A função valor V_t existe precisamente para **resumir** a incerteza futura em um único número que depende apenas do estado presente. Usar valores futuros nas features seria circular.

4.2 2. Como o futuro entra na aproximação?

O futuro entra **implicitamente**, através da equação de Bellman:

$$V_t(s) = \max_a \{u(a) + \beta \cdot \mathbb{E}_t[V_{t+1}(S_{t+1}, e_{t+1})]\} \tag{5}$$

A esperança $\mathbb{E}_t[V_{t+1}(\ldots)]$ captura o futuro, mas ela é **integrada via Monte Carlo** — amostrando realizações do choque futuro ξ — de modo que, ao ser avaliada, se torna apenas um número que depende do estado e da ação presentes.

4.3 3. Resumo

Componente	**Depende de...**
Features $\phi(s)$	Estado **presente** (S_t, e_t)
$\mathbb{E}_t[V_{t+1}(\ldots)]$	Estado presente + Monte Carlo sobre ξ futuro
Valores futuros S_{t+1}, e_{t+1}	Gerados durante a simulação, não entram nas features

Em suma: **features = estado presente. O futuro é tratado pelo passo de esperança/Monte Carlo.**

5 Dúvida 5: Qual o Propósito do Algoritmo de Computação de Targets? O que é Q_a e $\max_a Q_a$?

Pergunta: Não estou conseguindo entender o propósito desse algoritmo. O que é Q_a e a operação $\max_a Q_a$?

5.1 1. O que é Q_a?

Q_a é o **valor esperado de estar no estado** $(x^{(n)}, e^{(n)})$ **e tomar a ação** a — ou seja, é a **Q-function** (função de valor de ação):

$$Q_a \approx \mathbb{E}\big[V_{t+1}(S_{t+1}, e_{t+1}) \mid S_t = x^{(n)},\ e_t = e^{(n)},\ b_t = a\big] \tag{6}$$

Em palavras: *"Se hoje minha carteira vale $x^{(n)}$ e eu comprar/vender a unidades de ativo, quanto vale o meu futuro em média?"*

O algoritmo **estima essa esperança por Monte Carlo**: sorteia M choques $\xi^{(n,m)}$, calcula o estado futuro $S^{(m)}$ para cada um, avalia V_{t+1} naquele estado via aproximação linear $\langle \theta_{t+1}, \phi^{(m)} \rangle$, e tira a média:

$$Q_a = \frac{1}{M} \sum_{m=1}^{M} \big\langle \theta_{t+1},\ \phi\big(S^{(m)}, e^{(m)}\big) \big\rangle \tag{7}$$

5.2 2. O que é $\max_a Q_a$?

Após calcular Q_a para **cada ação possível** $a \in \mathcal{A}_{\text{discrete}}$, pega-se o máximo:

$$Y^{(n)} = \max_a Q_a \tag{8}$$

Isso é a **equação de Bellman na prática**: o valor ótimo do estado atual é o valor esperado do futuro, **maximizado sobre as ações disponíveis**. É a melhor decisão possível dado o estado $(x^{(n)}, e^{(n)})$.

5.3 3. Propósito geral do algoritmo

O algoritmo computa o **target** $Y^{(n)}$ — o valor "correto" que a função valor deveria ter no estado $(x^{(n)}, e^{(n)})$. Esse $Y^{(n)}$ será usado para **atualizar os coeficientes** θ_t da aproximação linear por regressão. É o passo *backward* da **Programação Dinâmica Aproximada (ADP)**.

Símbolo	Significado
Q_a	Valor esperado do futuro dado o estado atual e a ação a (estimado por Monte Carlo)
$\max_a Q_a$	Melhor Q_a entre todas as ações — aplica a equação de Bellman
$Y^{(n)}$	Target: o valor ótimo estimado para o estado n, usado para ajustar θ_t

6 Dúvida 6: O que é o Índice n? As Maximizações São Independentes?

Pergunta: O que é n? É cada banco? Encontramos um a diferente para cada banco? Podemos resolver múltiplos problemas de maximização independentemente e vai dar tudo certo?

6.1 1. O que é o índice n?

$n = 1, \ldots, N$ indexa os **pontos de amostra do espaço de estados** usados para treinar a regressão. Cada n corresponde a um estado amostrado $(x^{(n)}, e^{(n)})$, onde:

- $x^{(n)}$ = um possível valor de carteira hoje
- $e^{(n)}$ = um possível estado econômico hoje

Não é necessariamente "cada banco" — é cada **cenário de estado** que o algoritmo usa como dado de treino para ajustar θ_t.

6.2 2. Encontramos um a^* diferente para cada n?

Tecnicamente **sim**: para cada estado n, o $\arg\max_a Q_a$ pode retornar uma ação ótima diferente, porque o estado $(x^{(n)}, e^{(n)})$ é diferente. No entanto, o que o algoritmo **salva** não é a ação ótima a^*, mas o **valor ótimo** $Y^{(n)} = \max_a Q_a$. Esse $Y^{(n)}$ é o *target* da regressão.

6.3 3. As maximizações são independentes entre si?

Sim para a maximização, não para a regressão. O fluxo é o seguinte:

1. **Maximizações independentes:** Para cada n, calcula-se Q_a para cada a e tira-se o máximo. Essa etapa não depende dos outros n's — pode ser paralelizada.

2. **Acoplamento na regressão:** Após obter todos os pares $(x^{(n)}, Y^{(n)})$, resolve-se **um único problema de regressão** para ajustar os coeficientes θ_t:

$$\theta_t = \arg\min_{\theta} \sum_{n=1}^{N} \left(Y^{(n)} - \theta^\top \phi(x^{(n)}, e^{(n)})\right)^2 \tag{9}$$

   Esse passo acopla todos os n's — o θ_t aprendido deve funcionar bem para **todos** os estados simultaneamente.

Etapa	Natureza
Maximização $\max_a Q_a$ para cada n	**Independente** (paralelizável)
Regressão sobre todos os $(x^{(n)}, Y^{(n)})$	**Acoplada** (um único θ_t)

7 Dúvida 7: O que é uma Rollout Policy?

Pergunta: O que é uma *rollout policy*?

7.1 1. Definição

Uma **rollout policy** (política de rollout) é uma **regra de decisão simples e predefinida** usada para simular trajetórias futuras do sistema e estimar o valor de um dado estado, quando a função valor ótima ainda não está disponível.

Em termos formais, ao seguir a rollout policy π^{rollout} a partir do estado s no tempo t:

$$V_t^{\text{rollout}}(s) \approx \mathbb{E}\left[\sum_{\tau=t}^{T} \beta^{\tau-t} u(a_\tau) \;\middle|\; s_t = s,\ a_\tau = \pi^{\text{rollout}}(s_\tau)\right] \tag{10}$$

7.2 2. Por que usar?

Você não tem V_{t+1} durante as primeiras iterações do treinamento, então precisa de **alguma** forma de avaliar estados futuros. A rollout policy (por exemplo: "manter a carteira atual", "portfolio de pesos iguais", ou uma heurística simples) fornece um **limitante inferior** ao valor ótimo real — é subótima, mas computável e serve como ponto de partida.

7.3 3. Papel no algoritmo ADP

A rollout policy é usada principalmente como **inicialização**: no tempo terminal T, o valor é conhecido (e.g. $V_T = 0$ ou valor de liquidação). Nas iterações iniciais, antes de θ_{t+1} estar bem treinado, a rollout policy funciona como um *warm start* para estabilizar o treinamento.

Conceito	Significado
π^{rollout}	Regra de decisão fixa e simples
Valor de rollout	Recompensa esperada ao seguir π^{rollout} a partir de s
Propósito	Aproximar V_{t+1} quando a aproximação aprendida não está disponível

8 Dúvida 8: Como Chegamos nas Injeções a Partir do θ?

Pergunta: Depois de encontrarmos o θ, como chegamos nas injeções?

8.1 1. O que você tem após o treinamento

Após o algoritmo ADP rodar para trás de $t = T$ até $t = 0$, você obtém um conjunto de parâmetros para cada período:

$$\theta_0, \theta_1, \ldots, \theta_{T-1} \tag{11}$$

Cada θ_t define a função valor aproximada $V_t(s) \approx \theta_t^\top \phi(s)$.

8.2 2. Simulação forward: como obter as injeções

Agora você **simula para frente** a partir do estado inicial real (S_0, e_0). Em cada período t:

1. **Observe o estado atual** (S_t, e_t).
2. **Calcule Q_a para cada ação possível** $a \in \mathcal{A}_{\text{discrete}}$ usando Monte Carlo com o θ_{t+1} já aprendido:

$$Q_a = \frac{1}{M} \sum_{m=1}^{M} \theta_{t+1}^\top \phi\big(S_t + \xi^{(m)} + a,\ e^{(m)}\big) \tag{12}$$

3. **Escolha a injeção ótima**:

$$a_t^* = \arg \max_{a \in \mathcal{A}_{\text{discrete}}} Q_a \tag{13}$$

4. **Execute a ação**: injete a_t^* de capital. O choque real ξ_{t+1} se realiza e o sistema transita para o estado S_{t+1}.
5. **Repita** para $t + 1$ usando θ_{t+2}.

8.3 3. Resumo do fluxo completo

Fase	**Direção**	**O que produz**
Treinamento (ADP)	$t = T \to 0$ (backward)	$\theta_T, \theta_{T-1}, \ldots, \theta_0$
Execução (simulação)	$t = 0 \to T$ (forward)	Injeções $a_0^*, a_1^*, \ldots, a_{T-1}^*$

A **injeção** a_t^* é simplesmente a ação que maximiza o valor esperado do futuro dado o estado presente — o $\arg\max_a Q_a$ avaliado no estado real do sistema naquele instante.

9 Resumo: O Algoritmo Completo Passo a Passo

O algoritmo resolve o problema de **injeção ótima de capital** em um sistema bancário sujeito a choques aleatórios. Ele combina Programação Dinâmica Aproximada (ADP) com aproximação linear da função valor e Monte Carlo.

9.1 Visão Geral em Duas Fases

Fase	Direção	Objetivo
1. Treinamento (ADP)	$t = T \to 0$ (backward)	Aprender $\theta_0, \ldots, \theta_{T-1}$
2. Execução	$t = 0 \to T$ (forward)	Gerar injeções $a_0^*, \ldots, a_{T-1}^*$

9.2 Fase 1: Treinamento (Backward)

Inicialização: No tempo terminal T, define-se $V_T(s)$ com um valor conhecido (e.g., $V_T = 0$ ou valor de liquidação), e θ_T é inicializado por regressão ou por rollout policy.

Para cada período $t = T-1, T-2, \ldots, 0$**:**

1. **Amostrar estados de treinamento.** Sortear N estados $(x^{(n)}, e^{(n)})$ representativos do espaço de estados. Esses são os pontos de treino da regressão.

2. **Para cada estado** n**, computar o target** $Y^{(n)}$ (Algoritmo 1):

   (a) Sortear M choques i.i.d.: $\xi^{(n,1)}, \ldots, \xi^{(n,M)} \sim F_X$.

   (b) Para cada ação $a \in \mathcal{A}_{\text{discrete}}$, calcular a Q-function por Monte Carlo:

$$Q_a = \frac{1}{M} \sum_{m=1}^{M} \left\langle \theta_{t+1},\ \phi\big(x^{(n)} + \xi^{(n,m)} + a,\ e^{(n)} \odot \mathbb{1}_{\{x^{(n)}+\xi^{(n,m)}+a>0\}}\big) \right\rangle \tag{14}$$

   (c) Escolher o target como o valor ótimo:

$$Y^{(n)} = \max_{a \in \mathcal{A}_{\text{discrete}}} Q_a \tag{15}$$

3. **Atualizar** θ_t **por regressão.** Usar todos os pares $\{(x^{(n)}, e^{(n)}), Y^{(n)}\}_{n=1}^{N}$:

$$\theta_t = \arg\min_{\theta} \sum_{n=1}^{N} \left(Y^{(n)} - \theta^\top \phi(x^{(n)}, e^{(n)})\right)^2 \tag{16}$$

   Isso define a nova aproximação $V_t(s) \approx \theta_t^\top \phi(s)$.

9.3 Fase 2: Execução (Forward)

Para cada período $t = 0, 1, \ldots, T-1$**:**

1. **Observar o estado atual** (S_t, e_t).

2. **Calcular** Q_a **para cada ação** $a \in \mathcal{A}_{\text{discrete}}$ usando Monte Carlo com θ_{t+1}.

3. **Injetar o capital ótimo**: $a_t^* = \arg\max_a Q_a$

4. **Realizar o choque** $\xi_{t+1} \sim F_X$ e atualizar o estado: $S_{t+1} = S_t + \xi_{t+1} + a_t^*$

9.4 Diagrama do Algoritmo Completo

FASE 1 — TREINAMENTO (backward: $t = T \to 0$**)**

Inicializar θ_T (rollout policy ou valor terminal)
Para $t = T - 1$ **até** 0:
  Amostrar N estados $(x^{(n)}, e^{(n)})$ do espaço de estados
  Para cada n:
  Sortear M choques $\xi^{(n,m)} \sim F_X$
  Para cada $a \in \mathcal{A}$: calcular Q_a por Monte Carlo
  $Y^{(n)} \leftarrow \max_a Q_a$
  Resolver regressão $\to$ obter θ_t

FASE 2 — EXECUÇÃO (forward: $t = 0 \to T$**)**

Observar estado inicial (S_0, e_0)
Para $t = 0$ **até** $T - 1$:
  Calcular Q_a para cada a usando θ_{t+1}
  $a_t^* \leftarrow \arg\max_a Q_a$ (injeção ótima)
  Aplicar a_t^*, observar choque ξ_{t+1}, transitar para S_{t+1}

10 Dúvida 9: Como Escolhemos os $x^{(n)}$ para Cada Instante t? O que Muda na Regressão?

Pergunta: Como escolhemos os $x^{(n)}$ para cada instante t? Não deveríamos ir de trás para frente (de x_T até x_0)? Por que não usar a ação ótima calculada por Monte Carlo em vez da rollout policy? E se os $x^{(n)}$ são sempre da mesma distribuição, o que muda entre t e $t + 1$?

10.1 1. Como são escolhidos os $x^{(n)}$?

Os $x^{(n)}$ **não vêm de uma trajetória específica** — eles são amostrados de uma **distribuição que cobre o espaço de estados** relevante. Estratégias comuns:

- Grade regular de valores plausíveis de carteira
- Amostragem uniforme num intervalo $[x_{\min}, x_{\max}]$
- Simulações forward prévias (*experience replay*)

O objetivo é que θ_t aprenda $V_t(s)$ para **qualquer** s possível, não apenas ao longo de uma trajetória. Durante a execução, o sistema pode estar em qualquer estado, então a função valor precisa generalizar.

10.2 2. Não deveríamos ir de x_T até x_0 no espaço de estados?

Há uma distinção importante aqui. O que vai de trás para frente **é o tempo** t, não o espaço de estados:

Backward em t	$\theta_{T-1} \to \theta_{T-2} \to \cdots \to \theta_0$
Em cada t	os $x^{(n)}$ são amostrados independentemente

Uma abordagem alternativa chamada *in-sample ADP* faz exatamente o que o aluno intui: simula trajetórias forward de x_0 até x_T primeiro, salva os estados visitados, e usa esses estados como $x^{(n)}$ no passo backward. Isso funciona, mas exige simulação prévia e tem trade-offs de cobertura do espaço.

10.3 3. Por que usar rollout policy e não a ação ótima?

É um problema de **galinha e ovo**:

- Para usar a ação ótima ao gerar estados no instante t, você precisaria de θ_t para tomar a decisão ótima em $t-1$...
- Mas θ_t é exatamente o que você ainda está calculando!

A rollout policy quebra esse ciclo: ela é uma **política fixa e pré-definida** que não depende de nada que ainda está sendo aprendido. Além disso, usar a política ótima corrente criaria um **viés de distribuição** — os estados amostrados seriam concentrados apenas nas regiões que essa política visita, prejudicando a generalização de θ_t.

10.4 4. Se os $x^{(n)}$ são idênticos para todo t, o que muda na regressão?

Esta é a questão mais sutil. Os **inputs** $x^{(n)}$ podem ser iguais, mas os **targets** $Y^{(n)}$ **são completamente diferentes**:

No instante $t+1$ (já calculado):

$$Y^{(n)} = \max_a \frac{1}{M} \sum_m \langle \theta_{t+2},\, \phi(x^{(n)} + \xi^m + a) \rangle \tag{17}$$

No instante t (sendo calculado agora):

$$Y^{(n)} = \max_a \frac{1}{M} \sum_m \langle \theta_{t+1},\, \phi(x^{(n)} + \xi^m + a) \rangle \tag{18}$$

Como $\theta_{t+1} \neq \theta_{t+2}$, os targets são diferentes, e portanto a regressão produz $\theta_t \neq \theta_{t+1}$.

Mais fundamentalmente, $V_t(s)$ e $V_{t+1}(s)$ são **funções genuinamente diferentes** para o mesmo estado s:

- $V_t(s)$ = valor de estar em s faltando $T-t$ períodos para o final
- $V_{t+1}(s)$ = valor de estar em s faltando $T-t-1$ períodos para o final

Com menos tempo restante, um banco em dificuldade tem menos chances de se recuperar, logo $V_t(s) \geq V_{t+1}(s)$ em geral (mais tempo = mais opções). A regressão em cada t está aprendendo uma função diferente — o valor com um horizonte de tempo a mais.

Questão	**Resposta**
De onde vêm os $x^{(n)}$?	Distribuição sobre o espaço de estados (não de trajetória)
Backward em x?	O backward é em t, não em x. Estados por período são independentes
Por que rollout e não ótimo?	Galinha e ovo: θ_t ainda não existe quando você precisa dos estados.
O que muda em cada t?	Os targets $Y^{(n)}$ mudam porque usam um θ_{t+1} diferente.